วิชา 305432 เครือข่ายเซนเซอร์ (Sensor Networks)

IoT-CAD: Context-Aware Adaptive Anomaly Detection in IoT Systems Through Sensor Association

การตรวจจับสิ่งผิดปกติแบบรู้บริบทและปรับตัวได้ในระบบ IoT ผ่านการเชื่อมโยงความสัมพันธ์เซนเซอร์

2020 IEEE/ACM International Conference on Computer-Aided Design (ICCAD)

คณะผู้วิจัย: Rozhin Yasaei, Felix Hernandez, Mohammad Abdullah Al Faruque (UC Irvine)

นายธีรภัทร ภู่ระย้า ลำดับที่ 10

รหัสนิสิต 66362416

นิยามปัญหา: Environmental Anomaly (EA) เทียบกับ Sensing Device Anomaly (SDA)

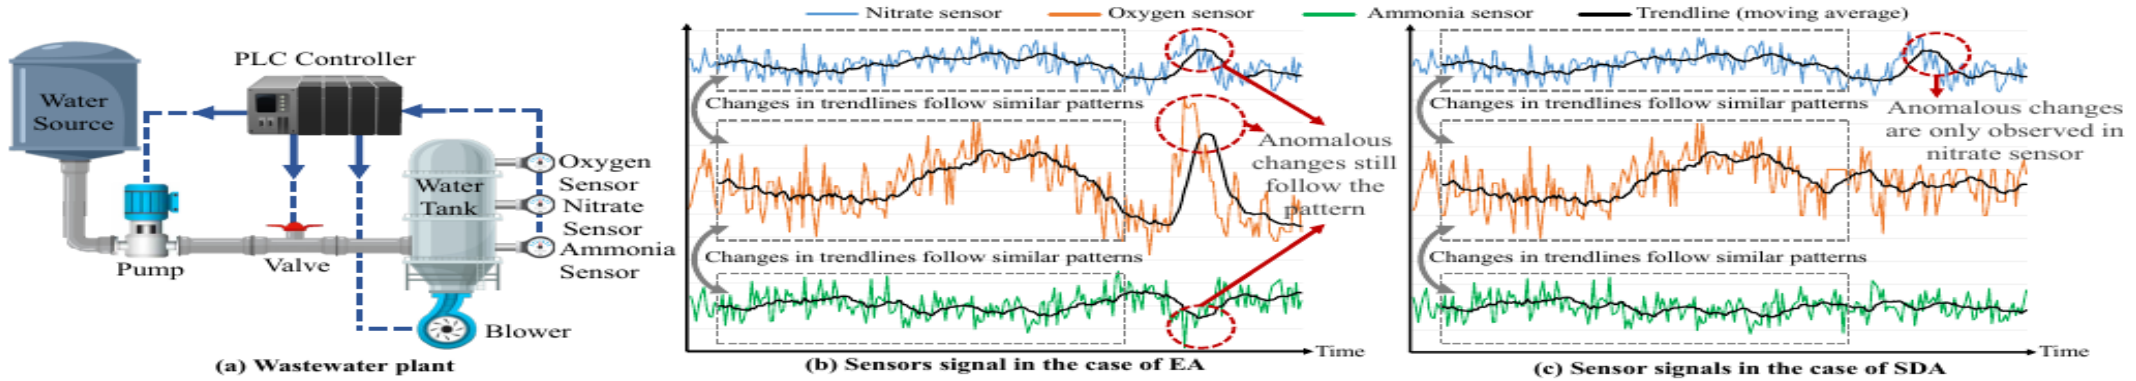


Figure 2: (a) Schema of wastewater plant, and synthetic sensors' signals in the (b) first scenario (EA), (c) second scenario (SDA).

1. Environmental Anomaly (EA)

- **นิยาม**: เกิดการเปลี่ยนแปลงทางกายภาพจริงในสภาวะแวดล้อม (เช่น เกิดเพลิงไหม้ หรือสารเคมีรั่วไหล)
- **พฤติกรรมสัญญาณ**: เซนเซอร์หลายชนิดที่เกี่ยวข้องจะเปลี่ยนแปลงไปในทิศทางสอดคล้องกัน (Correlated Signals)
- **การดำเนินการ**: ระบบต้องสั่งการมาตรการความปลอดภัย ไม่สรุปว่าเซนเซอร์ชำรุดหรือตัดสัญญาณทิ้ง

2. Sensing Device Anomaly (SDA)

- **นิยาม**: ตัวอุปกรณ์ตรวจวัดชำรุด เสื่อมสภาพ หรือสัญญาณถูกโจมตีทางไซเบอร์ (Sensor Data Tampering)
- **พฤติกรรมสัญญาณ**: สัญญาณของเซนเซอร์ตัวที่มีปัญหาจะมีค่าขัดแย้งกับสมาชิกในกลุ่มบริบทเดียวกัน (Uncorrelated)
- **การดำเนินการ**: ระบบสามารถระบุชี้เป้าเซนเซอร์ที่มีปัญหาได้อย่างเจาะจงเพื่อแจ้งทีมซ่อมบำรุงอุปกรณ์

สถาปัตยกรรมระบบ 3 ระดับ และกระบวนการทำงาน 4 ขั้นตอน

1. Edge Tier: โหนดตรวจวัดทางกายภาพ

- **หน้าที่**: รวบรวมข้อมูลดิบ (Raw Data) จากเซนเซอร์กายภาพในพื้นที่
- **การสื่อสาร**: ส่งข้อมูลผ่านโปรโตคอลไร้สายกำลังต่ำ IEEE 802.15.4 สู่เกตเวย์

2. Fog Tier: เกตเวย์และประมวลผลพื้นที่

- **จุดประมวลผลหลัก**: สกัด Fingerprint, ทำนายด้วยแบบจำลอง LSTM
- **การตัดสินใจ**: จำแนก Anomaly และโหวตฉันทามติแบบ Real-time หน้างาน

3. Cloud Tier: ระบบคลาวด์ส่วนกลาง

- **ฐานข้อมูลประวัติ**: จัดเก็บข้อมูลประวัติย้อนหลังระยะยาวเพื่อการวิเคราะห์
- **การฝึกสอนใหญ่**: ดำเนินการ Complete Retraining เมื่อมีการเปลี่ยนโครงสร้างระบบ

ขั้นที่ 1: Binary Fingerprint (สมการที่ 1)

แปลงทิศทางความเปลี่ยนแปลงสัมพัทธ์ในหน้าต่างเวลาเป็นบิต 0 และ 1 เพื่อตัดปัญหากำแพงหน่วยวัดทางกายภาพที่ต่างกัน (เช่น องศาเซลเซียส กับ ลักซ์)

ขั้นที่ 2: Sensor Association (Hamming Clustering)

วัดความคล้ายคลึงด้วย Hamming Distance และจัดกลุ่มด้วย Clustering 2 ระดับ โดยคลัสเตอร์ต้องมีสมาชิกตั้งแต่ 3 ตัวขึ้นไปเพื่อรองรับฉันทามติ

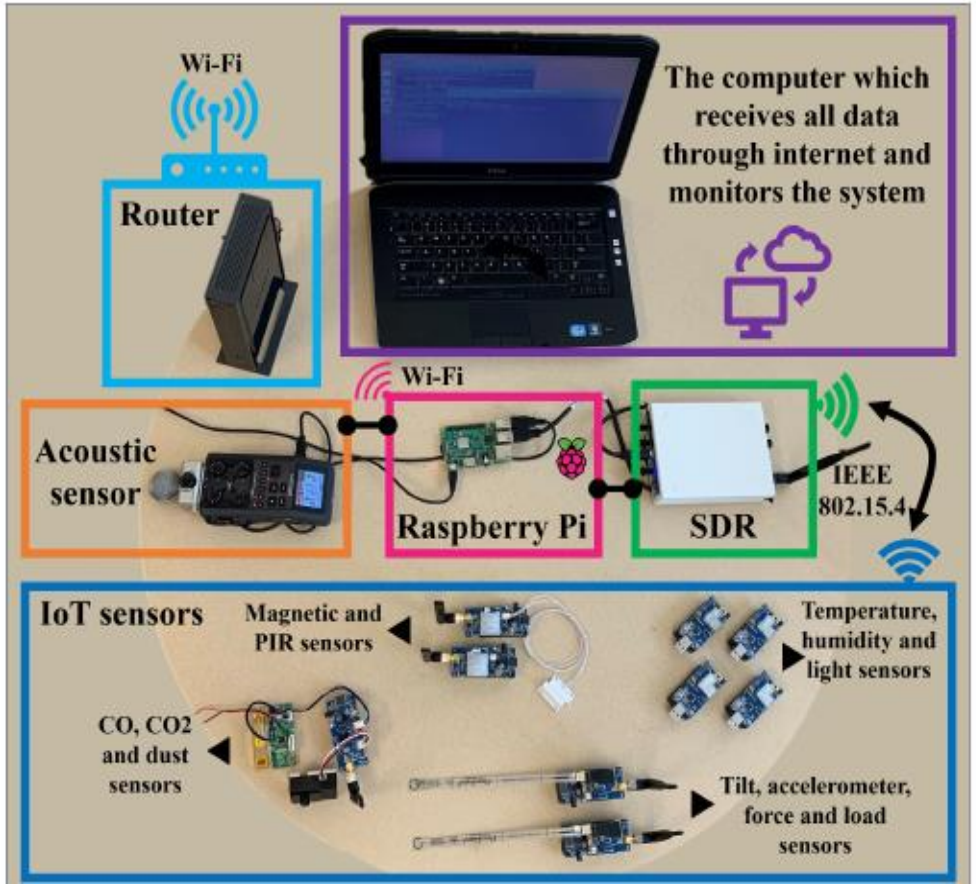
ขั้นที่ 3: Predictive Model (LSTM + Gaussian)

แต่ละคลัสเตอร์ใช้ LSTM Encoder-Decoder เรียนรู้พฤติกรรมปกติ และประเมินเวกเตอร์ Reconstruction Error ด้วย Multivariate Gaussian Distribution

ขั้นที่ 4: Consensus Algorithm & Adaptive Retrain

ใช้เสียงส่วนใหญ่ในคลัสเตอร์จำแนก EA vs SDA พร้อมระบุโหนดเสีย และ Retrain แบบ Adaptive เมื่อเกิดการเปลี่ยนแปลงในระบบ

สภาพแวดล้อมการทดสอบจริง (Hardware Testbed & Experimental Scope)



62 โหนด
เซนเซอร์ฮาร์ดแวร์จริง

13 ชนิด
ตัวแปรทางกายภาพ

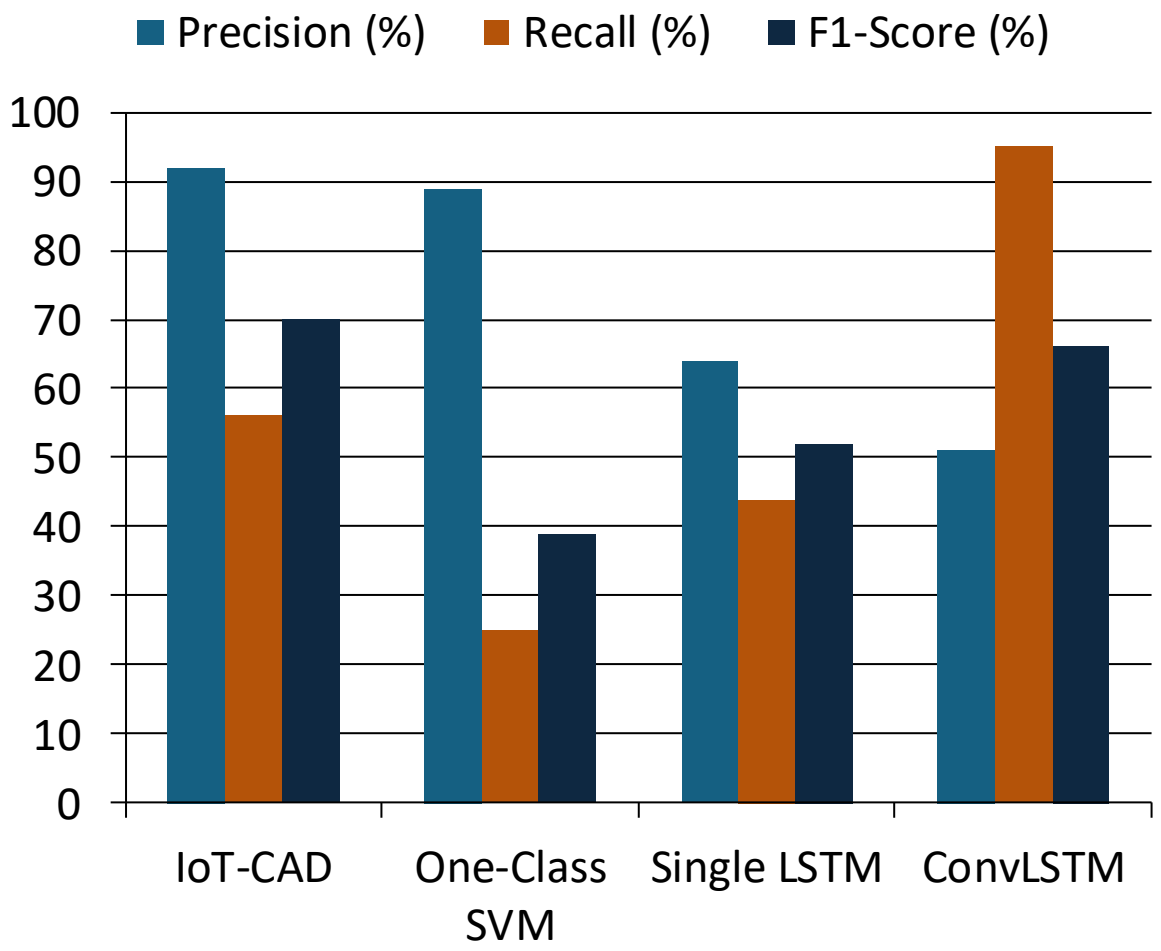
8 วัน
บันทึกสภาวะปกติ

2.3 ล้าน
จุดข้อมูลการวัดทั้งหมด

องค์ประกอบเครือข่ายและข้อกำหนดข้อมูล:

- **การเชื่อมต่อเครือข่าย**: โปรโตคอลไร้สาย IEEE 802.15.4 (TinyOS) รวบรวมผ่าน Raspberry Pi Gateway
- **โหนดประมวลผล Fog**: แล็ปท็อป Intel Core i5-6300HQ, RAM 8 GB ทำหน้าที่ประมวลผลหน้างาน
- **ข้อกำหนดข้อมูลที่สำคัญ**: ข้อมูลปกติเก็บจริง 8 วัน แต่ข้อมูลความผิดปกติเป็นข้อมูลสังเคราะห์ (Synthetic Anomaly) เพื่อความปลอดภัย

ผลการทดลองเชิงปริมาณ: การเปรียบเทียบ Precision, Recall และ F1-Score



Precision สูงสุด 92.0% (F1 รวม 70.0%)

เมื่อระบบส่งสัญญาณแจ้งเตือน มั่นใจได้ถึง 92% ว่าเกิดเหตุผิดปกติขึ้นจริง ช่วยขจัดปัญหาการเตือนภัยลวง (False Alarm Fatigue) ในระบบเฝ้าระวังอุตสาหกรรมได้อย่างมีนัยสำคัญ

Recall อยู่ที่ 56.0% (ยังมี False Negative 44.0%)

เกิดจากการตั้งค่าเกณฑ์ขีดเริ่มเปลี่ยนอัลฟ่าอย่างเข้มงวดเพื่อกด False Positive ทำให้ความผิดปกติบางรูปแบบหลุดรอดการตรวจจับ จึงยังไม่เหมาะกับระบบ Safety-Critical

เวลาประมวลผล (Latency): 0.532 วินาทีต่อรอบ

ความเร็วในการประมวลผล 0.532 วินาที เร็วกว่ารอบการเก็บข้อมูลของเซนเซอร์ ยืนยันว่าระบบสามารถทำงานแบบ Real-time บนโหนด Fog ได้จริง

แหล่งข้อมูล: Table 2 และ Table 3 จาก Yasaei et al., ICCAD 2020 (เปรียบเทียบ One-Class SVM, LSTM, ConvLSTM)

การมีส่วนร่วมทางวิชาการ (Academic Contributions)

1. การเชื่อมโยงเซนเซอร์ต่างชนิดโดยอาศัยบริบท (Cross-Modal Sensor Association) [Section 3.2, Algorithm 1]

นำเสนอเทคนิค Binary Fingerprint ที่แปลงพลวัตการเปลี่ยนแปลงของค่าสัญญาณให้เป็นลำดับบิต 0 และ 1 ช่วยขจัดกำแพงเรื่องความแตกต่างของหน่วยวัดทางกายภาพ ทำให้ระบบสามารถคำนวณ Hamming Distance และจัดกลุ่มเซนเซอร์ต่างประเภท (เช่น เซนเซอร์วัดแสง กับ เซนเซอร์วัดอุณหภูมิ) ได้อย่างอัตโนมัติ โดยไม่ต้องกำหนดความสัมพันธ์ทางกายภาพด้วยมือ

2. กลไกฉันทามติเพื่อจำแนกประเภทและระบุต้นทางความผิดปกติ (Consensus-Based Disambiguation) [Section 3.4, Algorithm 2]

พัฒนาการตรวจจับความผิดปกติให้ก้าวข้ามการบอกเพียงว่าข้อมูลผิดปกติหรือไม่ โดยใช้เสียงส่วนใหญ่ของคลัสเตอร์เพื่อแยกแยะระหว่าง Environmental Anomaly (EA) ออกจาก Sensing Device Anomaly (SDA) พร้อมทั้งระบุหมายเลขโหนดที่เป็นต้นเหตุได้อย่างเจาะจงเพื่อการบำรุงรักษาอุปกรณ์

3. สถาปัตยกรรมการปรับตัวแบบเพิ่มพูนบน Fog Computing (Adaptive Model Updating) [Section 3.4, Subsection D]

ออกแบบกลไกการปรับปรุงโมเดลสองระดับ ได้แก่ Partial Update บน Fog Node เพื่อรองรับการเปลี่ยนแปลงของสภาพแวดล้อม และ Complete Retrain เมื่อมีการเพิ่มลดโหนดในเครือข่าย โดยฝึกสอนใหม่เฉพาะคลัสเตอร์ที่ได้รับผลกระทบ ช่วยลดภาระการประมวลผลและการส่งข้อมูลขึ้นคลาวด์

ข้อจำกัด และบทสรุป

ข้อจำกัดที่ระบุในบทความ (Limitations & Risks)

1. อัตรา Recall 56% ยังไม่เหมาะกับระบบวิกฤต

การปล่อยให้ Anomaly หลุดรอดไปถึง 44% ถือเป็นความเสี่ยงที่ไม่สามารถยอมรับได้ในระบบความปลอดภัยสูง (Safety-Critical) เช่น ระบบแจ้งเตือนอัคคีภัยหรือโรงไฟฟ้านิวเคลียร์

2. การประเมินผลด้วยข้อมูลสังเคราะห์ระยะสั้น

ข้อมูล Anomaly ทั้งหมดสร้างด้วยแบบจำลองคณิตศาสตร์ และบันทึกข้อมูลปกติเพียง 8 วันในอาคารเดียว ยังไม่ได้ทดสอบความทนทานต่อสภาพอากาศข้ามฤดูกาล

3. ความเสี่ยงต่อการโจมตีแบบ Coordinated Attack

ต้องมีเซนเซอร์อย่างน้อย 3 ตัวในคลัสเตอร์จึงจะทำฉันทามติได้ และหากผู้โจมตีเจาะระบบเซนเซอร์ได้พร้อมกันเกินครึ่งกลุ่ม ระบบจะถูกหลอกให้ตัดสินเป็น EA

บทสรุปและการประยุกต์ใช้งาน (Conclusion & Applications)

1. ประโยชน์หลักต่อเครือข่ายเซนเซอร์ IoT

พิสูจน์ว่าความสัมพันธ์ข้ามมิติของเซนเซอร์ช่วยลด False Alarm ได้อย่างเด็ดขาด (Precision 92%) บนสถาปัตยกรรม Fog โดยไม่ต้องพึ่งพา Cloud ตลอดเวลา

2. การนำไปต่อยอดในโครงงานวิศวกรรม

สามารถนำหลักการ Cross-Sensor Association ไปต่อยอดตรวจสอบ Data Integrity ในระบบเกษตรแม่นยำ (Smart Agriculture) หรือตรวจสภาพเครื่องจักรโรงงาน

3. ทิศทางการปรับปรุงระบบในอนาคต

ควรปรับจูนเกณฑ์อัลฟ่าให้ยืดหยุ่นตามระดับความเสี่ยงของแต่ละพื้นที่ และทดสอบกับชุดข้อมูลการโจมตีทางไซเบอร์ของจริง

เอกสารอ้างอิง: Yasaei et al., ICCAD 2020 (IEEE Xplore: 9256703, DOI: 10.1145/3400302.3415672)